

## CHAPTER 1. 신경망 복습

### 1.1 수학과 파이썬 복습

#### 1.1.1 벡터와 행렬

`W = np.array([[1, 2, 3], [4, 5, 6]])`

`W.shape` → (2, 3)    다차원 배열의 크기

`W.ndim` → 2    차원수

#### 1.1.2 행렬의 원소별 연산

#### 1.1.3 브로드캐스트

#### 1.1.4 벡터의 내적과 행렬의 곱

$$X \cdot Y = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$


- 행렬의 곱: 왼쪽 행렬의 행벡터와 오른쪽 행렬의 열벡터의 내적.

#### 1.1.5 행렬 곱셈 확인

### 1.2 신경망의 추론

- "학습"과 "추론"

#### 1.2.1 신경망 추론 전체 그림



$$- h_1 = x_1 w_{11} + x_2 w_{21} + b_1$$


$$- (h_1, h_2, h_3, h_4) = (x_1, x_2) \begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{pmatrix} + (b_1, b_2, b_3, b_4)$$

(1, 4)                  (1, 2)                  (2, 4)

↓ 간소화

$$- h = xW + b$$

- 디바이스



- '비선형' 효과를 부여하기 위해 활성화함수 사용.

예) 시그모이드


$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

### 1. 2. 2. 계층으로 클래스와 순서쌍 구현

- Affine : 완전연계 계층에 의한 변환
- Sigmoid : 시그모이드 함수에 의한 변환

#### ★ 구현 규칙

- 모든 계층은 forward() 와 backward() 메서드를 가진다.
- 모든 계층은 인스턴스 변수인 params 와 grads 를 가진다.
  - params : 가중치, 편향 등을 담은 리스트
  - grads : params 에 저장된 각 매개변수에 대응하여,  
해당 매개변수의 기울기를 보관하는 리스트



↳ TwoLayerNet 클래스를 추상화

```
X = np.random.randn(10, 2)
model = TwoLayerNet(2, 4, 3)
s = model.predict(X)
```

### 1.3 신경망의 학습


- 최적의 매개변수의 값을 찾는 작업.

#### 1.3.1 손실함수

- 손실 : 학습데이터 (학습 시 주어진 정답데이터)와 신경망이 예측한 결과를 비교,

예측이 얼마나 나쁠가를 산출하는 단일값 (스칼라)

- 손실함수 : 다중의 경우 Cross Entropy Error



- 소프트맥스 함수

$$y_k = \frac{\exp(S_k)}{\sum_{i=1}^n \exp(S_i)}$$

출력이 총 n개일 때,  
k번째 출력  $y_k$ 를 구하는 계산식  
 $y_k$ 는 k번째 클래스에 해당하는 소프트맥스 함수의 출력.

exp : 지수  $S_k$ 의 지수 함수

sum : 모든 입력신호의 지수 함수의 총합

↓  
소프트맥스의 출력 (= 확률)이 교차 엔트로피 요인에 입력됨.

- 교차 엔트로피의 수식

$$L = -\sum_k t_k \log y_k \rightarrow \text{정답레이블이 1인 원소에 해당하는 출력의 자연로그의 계산.}$$

t : k번째 클래스에 해당하는 정답레이블

$t = [0, 0, 1]$  과 같이 원핫벡터로 표기

- 디바이스 고려

$$L = -\frac{1}{N} \sum_n \sum_k t_{nk} \log y_{nk}$$

t<sub>nk</sub> : n번째 데이터의 k 차원 째 값 의미, 정답레이블

y<sub>nk</sub> : 신경망의 출력.

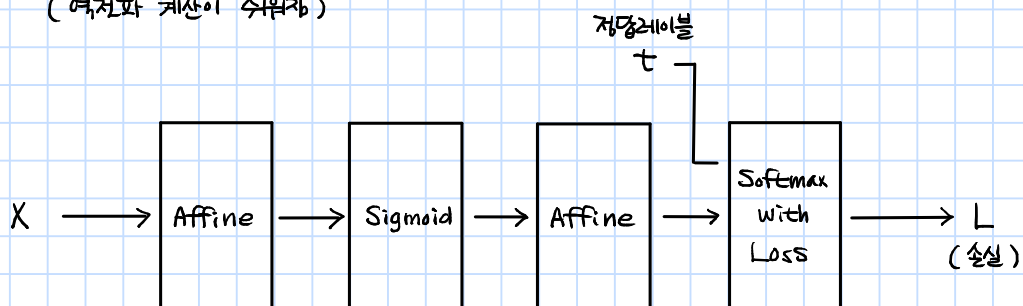
• N개짜리로 확장.

• N으로 나눠서 '평균 손실 함수'를 구함.

→ 디바이스의 크기에 관계없이 항상 일관된 차등을 얻을 수 있음.

- 소프트맥스나 교차 엔트로피 요인을 Softmax with Loss 계층으로 구현

(여전과 계산이 쉬워짐)



완전연결층에 의한 변환의 디버깅 버전

```
import numpy as np
```

```
W1 = np.random.randn(2,4) # 가중치
```

```
b1 = np.random.randn(4) # 편향
```

```
x = np.random.randn(10, 2) # 입력 : 각 샘플데이터
```

```
h = np.matmul(x, W1) + b1  
# 브로드캐스트 됨.
```

```
def sigmoid(x):
```

```
    return 1 / (1 + np.exp(-x))
```

```
a = sigmoid(h)
```

중첩

```
import numpy as np
```

```
def sigmoid(x):
```

```
    return 1 / (1 + np.exp(-x))
```

```
x = np.random.randn(10, 2) # 입력 : 각 샘플데이터
```

```
W1 = np.random.randn(2,4) # 가중치
```

```
b1 = np.random.randn(4) # 편향
```

```
W2 = np.random.randn(4,3) → 은닉층 뉴런 4개, 출력층 뉴런 3개이므로 4x3 계상으로 설정.
```

```
b2 = np.random.randn(3)
```

```
h = np.matmul(x, W1) + b1
```

```
a = sigmoid(h)
```

```
s = np.matmul(a, W2) + b2
```

↓  
최종출력 (10, 3)

: 10개의 데이터가 한꺼번에 들어,  
각 데이터는 3차원 데이터를 반환함.

```
import numpy as np
```

```
class Sigmoid:
```

```
    def __init__(self):
```

```
        self.params = []
```

```
    def forward(self, x):
```

```
        return 1 / (1 + np.exp(-x))
```

```
class Affine :
```

```
    def __init__(self, W, b):
```

```
        self.params = [W, b] → 초기화될 때 가중치와 편향을 받음.  
                               (신경망이 학습될 때 수치를 갱신)
```

```
    def forward(self, x):
```

```
        W, b = self.params
```

```
        out = np.matmul(x, W) + b
```

```
        return out
```

```
class TwoLayerNet:
```

```
    def __init__(self, input_size, hidden_size, output_size):
```

```
        I, H, O = input_size, hidden_size, output_size
```

```
        # 가중치와 편향 초기화
```

```
        W1 = np.random.randn(I, H)
```

```
        b1 = np.random.randn(H)
```

```
        W2 = np.random.randn(H, O)
```

```
        b2 = np.random.randn(O)
```

```
        # 계층 생성
```

```
        self.layers = [Affine(W1, b1),
```

```
                        Sigmoid(),
```

```
                        Affine(W2, b2)]
```

```
        # 모든 가중치를 리스트에 모은다.
```

```
        self.params = []
```

```
        for layer in self.layers:
```

```
            self.params += layer.params
```

→ 모든 계층은 자신의 학습 매개변수들을  
인스턴스 변수인 params에 보관하고 있으므로  
변수들을 더해주기만 하면 됨!

```
    def predict(self, x):
```

```
        for layer in self.layers:
```

```
            x = layer.forward(x)
```

```
        return x
```

